



دانشگاه صنعتی شریف
دانشکده مهندسی کامپیوتر

پروژه درس پردازش زبان های طبیعی
مهندسی کامپیوتر

سیستم RAG با پشتیبانی از داده های چندوجهی در حوزه هی مشاهیر

نگارش

۱۹ و ۸۰ گروه

استاد

دکتر احسان الدین عسگری

۱۴۰۴ شهریور

الله اعلم

چکیده

امروزه سیستم‌های پرسش و پاسخ مبتنی بر مدل‌های زبان بزرگ با چالش‌هایی نظیر تولید اطلاعات نادرست (توهم) و محدودیت دانش مواجه هستند. معماری بازیابی-افزایش-تولید (RAG) با اتصال مدل به یک پایگاه دانش خارجی، راهکاری مؤثر برای این مشکلات ارائه می‌دهد. با این حال، بسیاری از این سیستم‌ها به اطلاعات متنی محدود هستند و از دانش غنی موجود در تصاویر غفلت می‌کنند. این پژوهش بر طراحی و پیاده‌سازی یک سیستم پرسش و پاسخ چندوجهی (Multimodal-RAG) برای زبان فارسی، با تمرکز بر دامنه دانش شخصیت‌های ایرانی، متمرکز است. برای این منظور، ابتدا یک پایگاه دانش شامل بیوگرافی‌های متنی و تصاویر مرتبط جمع‌آوری شد. سپس، یک مدل Encoder دوگانه با استفاده از یادگیری تقابلی (Contrastive-Learning) آموزش داده شد تا بتواند بازنمایی‌های برداری همتراز برای جفت‌های متن-تصویر تولید کند. این مدل به عنوان بخش بازیاب (Retriever) در یک پایپ‌لاین کامل RAG به کار گرفته شد تا اسناد و تصاویر مرتبط با سوال کاربر را بازیابی کرده و در اختیار یک مدل زبان بزرگ (Generator) قرار دهد. ارزیابی نهایی بر روی یک مجموعه سوالات چهارگزینه‌ای نشان داد که مدل چندوجهی پیشنهادی، با بهره‌گیری از اطلاعات تصویری، به دقت بالاتری نسبت به مدل‌های صرفاً متنی دست می‌یابد و توانایی سیستم در پاسخگویی دقیق‌تر را اثبات می‌کند. دستاوردهای این پژوهش شامل یک دموی تحت وب و انتشار مدل Encoder آموزش‌دیده برای استفاده عمومی است.

کلیدواژه‌ها: پرسش و پاسخ چندوجهی، معماری RAG بازیابی اطلاعات، یادگیری تقابلی، پردازش زبان طبیعی فارسی، مدل‌های متن-تصویر.

فهرست مطالب

۱	۱	مقدمه
۲	۱-۱	هدف و مسئله پژوهش
۳	۲	روش‌ها و داده
۴	۱-۲	جمع آوری داده
۵	۱-۱-۲	کرال کردن داده ها
۶	۱-۱-۲	پاکسازی داده ها پس از کرال
۷	۱-۲	فرمت داده ها در JSON
۸	۲-۲	استخراج و ساختاردهی دادگان
۹	۱-۲-۲	گردآوری و تجمیع دادگان جامع از مشاهیر ایرانی
۱۰	۱-۲-۲	بررسی و برچسب‌گذاری داده‌های جمع آوری شده
۱۱	۲-۲-۲	بهبود دادگان
۱۲	۱-۳-۲	تولید متن برای هر شخص از داده های غیر تصویری جمع آوری شده
۱۳	۲-۳-۲	تولید توضیحات تصویر اشخاص به متن داده ها
۱۴	۳-۳-۲	مرح کردن داده های جفت گروه
۱۵	۴-۲	ساخت مدل Encoder برای RAG
۱۶	۱-۴-۲	پیش‌پردازش و آماده‌سازی داده‌ها برای مدل
۱۷	۲-۴-۲	بهینه‌سازی مدل برای تولید Embedding

۱۵	ساخت سیستم بازیابی (Retrieval)	۳-۴-۲
۱۶	ارزیابی عملکرد سیستم بازیابی	۴-۴-۲
۱۸	ساخت مدل end-to-end برای RAG	۵-۲
۱۸	معماری و اجزای سیستم	۱-۵-۲
۱۹	فرآیند تولید پاسخ	۲-۵-۲
۲۱	نتایج و دستاوردها	
۲۱	ارزیابی مدل نهایی RAG End-to-End	۱-۳
۲۲	معیارهای ارزیابی	۱-۱-۳
۲۳	تحلیل نتایج کمی و کیفی	۲-۱-۳
۲۴	پیاده‌سازی و ارائه دموی تحت وب	۲-۳
۲۴	آدرس دسترسی و مشخصات دمو	۱-۲-۳
۲۵	انتشار مدل نهایی در Hugging-Face	۳-۳
۲۶	انتشار کد و داده‌ها در Github	۴-۳
۲۷	نتیجه‌گیری و کارهای آینده	
۲۷	خلاصه دستاوردها	۴-۱
۲۸	محدودیت‌ها و کارهای آینده	۲-۴
۳۰	مراجع	

فصل ۱

مقدمه

توانایی انسان در درک جهان، حاصل تلفیق اطلاعات از حواس مختلف، به ویژه بینایی و زبان است. سیستم‌های هوش مصنوعی نوین نیز برای دستیابی به درکی عمیق‌تر، نیازمند فرارفتن از مرزهای متنی و ورود به دنیای چندوجهی (Multimodal) هستند. در حوزه پردازش زبان طبیعی، مدل‌های زبان بزرگ (LLMs) با وجود توانمندی‌های چشمگیر در تولید متن، به دو ضعف عمدۀ مشهورند: تمایل به تولید اطلاعات نادرست یا توهם (*Hallucination*) و عدم آگاهی از اطلاعات جدیدی که پس از تاریخ آموزش آنها رخ داده است.

معماری بازیابی-افزایش-تولید^۱ به عنوان یک راهکار پیشرو برای مقابله با این چالش‌ها ظهرور کرده است. ایده کلیدی در، RAG مجهز کردن مدل زبان به یک پایگاه دانش خارجی است. پیش از تولید پاسخ، سیستم ابتدا اسناد مرتبط با پرسش کاربر را از این پایگاه بازیابی کرده و به عنوان "زمینه" (Context) در اختیار مدل قرار می‌دهد. این فرآیند، پاسخ‌ها را به سمت اطلاعات واقعی و مستند هدایت می‌کند.

با این حال، دانش ما تنها در قالب متن خلاصه نمی‌شود. یک تصویر می‌تواند حاوی جزئیاتی باشد که توصیف آن در هزاران کلمه نیز دشوار است. برای مثال، درک کامل یک شخصیت تاریخی بدون دیدن تصویر او ناقص است. این واقعیت، انگیزه اصلی این پژوهش برای حرکت به سوی RAG چندوجهی است؛ سیستمی که قادر است به طور همزمان از منابع اطلاعاتی متنی و تصویری برای پاسخ به پرسش‌ها بهره ببرد.

Generation Retrieval-Augmented^۱

۱-۱ هدف و مسئله پژوهش

این پژوهش بر طراحی و پیاده‌سازی یک سیستم پرسش و پاسخ چندوجهی برای زبان فارسی در دامنه دانش شخصیت‌های عمومی ایران تمرکز دارد. با توجه به کمبود منابع داده چندوجهی در زبان فارسی، این پژوهه یک راهکار یکپارچه برای حل این مسئله ارائه می‌دهد:

۱. ساخت پایگاه دانش چندوجهی: جمع‌آوری و پالایش مجموعه‌ای از بیوگرافی‌های متنی و تصاویر مرتبط با شخصیت‌ها.

۲. توسعه مدل بازیاب (Retriever) چندوجهی: آموزش یک مدل Encoder دوگانه که بتواند با دریافت یک پرسش (متنی یا تصویری)، مرتبطترین اسناد متنی و تصویری را از پایگاه دانش بازیابی کند.

۳. پیاده‌سازی و ارزیابی سیستم یکپارچه: ادغام مدل بازیاب با یک مدل زبان بزرگ (Generator) برای ساخت یک سیستم سرتاسر که قادر به پاسخگویی دقیق به سوالات است.

این پژوهه نه تنها یک راهکار عملی برای پرسش و پاسخ هوشمند ارائه می‌دهد، بلکه با ایجاد زیرساخت داده و مدل، گامی در جهت توسعه پژوهش‌های چندوجهی در زبان فارسی برمی‌دارد.

فصل ۲

روش‌ها و داده

۱-۲ جمع آوری داده

اساس یک سیستم بازیابی اطلاعات کارآمد، مجموعه‌دادهای جامع و باکیفیت است. در این پژوهه، با هدف ساخت یک سیستم پاسخگویی چندوجهی در حوزه مشاهیر، فاز اول به جمع آوری داده‌های متنی و تصویری از دانشنامه آنلاین ویکی‌پدیا فارسی اختصاص یافت. ویکی‌پدیا به دلیل پوشش گسترده اطلاعاتی، ساختار نیمه‌منظمه صفحات (infobox) و در دسترس بودن تصاویر مرتبط، به عنوان منبع اصلی انتخاب گردید. فرآیند جمع آوری داده شامل چندین مرحله‌ی دقیق از جمله خزش وب، پاکسازی و رفع نویز، و نهایتاً ساختارمندسازی اطلاعات بود که در ادامه به تفصیل تشریح می‌گردد.

۱-۱-۲ کردن داده‌ها

با توجه به ماهیت پویا و ساختار درختی و تودرتوی دسته‌بندی‌های ویکی‌پدیا، پیمایش دستی برای استخراج داده‌ها امری غیرممکن و مستعد خطا بود. از این رو، یک خزشگر (Crawler) خودکار با استفاده از زبان برنامه‌نویسی پایتون پیاده‌سازی شد. این خزشگر با بهره‌گیری از API رسمی مدیاویکی، فرآیند پیمایش را به صورت برنامه‌ریزی شده انجام داد.

با الهام از ساختار گرافی ویکی‌پدیا که در آن هر صفحه یک گره (Node) و هر پیوند یک یال (Edge) است، الگوریتم جستجوی سطح به سطح (BFS) برای پیمایش انتخاب شد. این الگوریتم با شروع از یک دسته ریشه (در پژوهه ما، دسته‌هایی که با عبارت «سیاست‌مداران اهل ایران» آغاز می‌شوند)، ابتدا تمام زیردسته‌های سطح اول را پیمایش کرده و سپس به سطوح عمیق‌تر می‌رود. این رویکرد تضمین می‌کند که

پیمایش به صورت کنترل شده پیش رفته و از افتادن در شاخه های بسیار عمیق و نامرتبط جلوگیری شود. برای جلوگیری از پیمایش تکراری و ایجاد حلقه، از یک مجموعه visited برای نگهداری شناسه های صفحات و دسته های بازدید شده استفاده گردید.

خروجی نهایی این مرحله، فایلی با فرمت CSV بود که شامل فهرستی از عنوانین صفحات (مقالات) مرتبط با حوزه هدف به همراه لینک دسترسی به آنها بود.

این روش مربوط به حوزه مشاهیر سیاسی بود که بطور خاص گروه ما با آن در ارتباط بود.

۲-۱-۲ پاکسازی داده ها پس از کمال

فهرست اولیه عنوانین تولید شده توسط خرزشگر، حاوی نویز قابل توجهی بود؛ برای مثال، شامل عنوانینی می شد که به مفاهیم، رویدادها یا لیست ها اشاره داشتند و نه به یک شخص حقیقی. بنابراین، یک فرآیند دومرحله ای برای رفع نویز و اعتبارسنجی داده ها طراحی شد:

۱. اعتبارسنجی موجودیت انسان: در این گام، با استفاده از API ویکی داده (Wikidata) برای هر عنوان صفحه، شناسه موجودیت Entity ID متناظر استخراج شد. سپس با بررسی ویژگی P31، مشخص گردید که آیا آن موجودیت از نوع «انسان» Q5 است یا خیر. عنوانینی که این شرط را احراز نمی کردند، به عنوان نویز شناسایی و از مجموعه داده حذف شدند. این فرآیند منجر به تولید یک لیست خالص از عنوانین صفحات متعلق به اشخاص حقیقی شد.

۲. فیلتر بر اساس جعبه اطلاعات: (Infobox) جعبه اطلاعات (Infobox) منبعی غنی از داده های ساختار یافته و کلیدی است. در این مرحله، برای هر صفحه معتبر، محتوای HTML آن دریافت و با استفاده از کتابخانه BeautifulSoup وجود جدولی با کلاس infobox بررسی شد. صفحاتی که قادر این جعبه اطلاعاتی بودند، از لیست نهایی کنار گذاشته شدند، زیرا داده های ساختار یافته ای لازم برای فاز بهبود دادگان را در اختیار نداشتند.

برای رعایت سیاست های استفاده از API و جلوگیری از فشار بر سرورهای ویکی پدیا و ویکی داده، از یک نشست Session HTTP با شناسه کاربری مشخص و همچنین تابع time.sleep برای ایجاد تأخیر بین درخواست های متوالی استفاده شد.



شکل ۲: یک نمونه **infobox** مربوط به صفحه ویکی‌پدیا دکتر حسابی

۳-۱-۲ فرمت داده‌ها در JSON

پس از اتمام مراحل پاکسازی و اعتبارسنجی، گام حیاتی بعدی، تبدیل داده‌های نیمه‌ساختاریافته‌ی استخراج شده به یک فرمت کاملاً ساختاریافته، استاندارد و غنی بود. برای این منظور، یک شیمای دقیق در قالب JSON طراحی گردید. هدف از این شیما، فراتر از ذخیره‌سازی ساده‌ی داده‌ها بود؛ این ساختار به عنوان یک مدل مفهومی عمل می‌کند که اطلاعات حیاتی هر شخص را به صورت تفکیک‌شده، سلسله‌مراتبی و قابل فهم برای ماشین، سازماندهی می‌نماید. فرآیند پر کردن این شیما شامل یک مرحله استخراج اطلاعات بود که طی آن، موجودیت‌های کلیدی از متن بیوگرافی و جدول اطلاعات (Infobox) شناسایی و در فیلدهای مربوطه نگاشت داده می‌شدند.

همانطور که در شکل ۲-۲ نشان داده شده است، این ساختار شامل فیلدهای کلیدی مانند name، sex و nick-names برای اطلاعات هویتی پایه است. اطلاعات مربوط به تولد و وفات در اشیاء تودرتوی birth و death سازماندهی شده‌اند که هر کدام شامل تاریخ، مکان (استان و شهر) و حتی مختصات coordinates (جغرافیایی) می‌باشند. فیلدهای مهم دیگری نظیر era (دوره تاریخی)، occupation (لیست مشاغل)، works (آثار) و در نهایت image (لیستی از URL تصاویر) این مدل داده را تکمیل می‌کنند.

```


1  {
2      "name": "",
3      "sex": "",
4      "nick-names": [],
5      "birth": {
6          "date": "",
7          "location": {
8              "province": "",
9              "city": "",
10             "coordinates": {
11                 "latitude": "",
12                 "longitude": ""
13             }
14         }
15     },
16     "death": {
17         "date": "",
18         "location": {
19             "province": "",
20             "city": "",
21             "coordinates": {
22                 "latitude": "",
23                 "longitude": ""
24             }
25         },
26         "tomb_location": {
27             "province": "",
28             "city": "",
29             "coordinates": {
30                 "latitude": "",
31                 "longitude": ""
32             }
33         }
34     },
35     "era": "",
36     "occupation": [],
37     "works": [],
38     "events": [],
39     "image": []
40 }

```

شکل ۲-۲: شماتیک استاندارد JSON برای ذخیره‌سازی اطلاعات هر شخص

۲-۲ استخراج و ساختاردهی دادگان

پس از تعریف دقیق شِمای JSON فاز پیاده‌سازی و اجرای پایپ‌لاین استخراج داده‌ها آغاز گردید. هدف این فاز، پر کردن خودکار شِمای تعریف شده برای هر یک از مشاهیر شناسایی شده در مرحله قبل بود. این فرآیند، که معماری کلی آن در شکل ۲-۳ نمایش داده شده است، یک رویکرد چندمنبعی (Multi-source) را برای تجمعی و اعتبارسنجی اطلاعات به کار می‌گیرد.



شکل ۲-۳: دیاگرام پایپ‌لاین استخراج، تلفیق و ذخیره‌سازی داده برای هر شخص.

همانطور که در دیاگرام مشهود است، پایپ‌لاین به ازای هر شخص (هر ردیف از فایل ورودی) یک بار اجرا می‌شود. روند کلی به شرح زیر است:

۱. بارگذاری ورودی و شروع حلقه: فرآیند با خواندن فایل که حاوی لینک صفحات ویکی‌پدیای مشاهیر است، آغاز می‌شود. یک حلقه بر روی هر ردیف از این فایل تکرار شده و برای هر شخص، مراحل بعدی اجرا می‌گردد.

۲. استخراج موازی از منابع اولیه: برای هر شخص، سه منبع اصلی اطلاعات به صورت موازی فراخوانی می‌شوند تا داده‌های خام اولیه جمع‌آوری شوند:

- دریافت خلاصه صفحه (`fetch_wiki_summary`): چکیده یا پاراگراف‌های ابتدایی صفحه ویکی‌پدیا از طریق API مربوطه دریافت می‌شود. این متن منبع خوبی برای اطلاعات کلی و یافتن کلیدواژه‌هایی است که ممکن است در بخش‌های دیگر نباشند.

- دریافت جعبه اطلاعات (`fetch_infobox`): جعبه اطلاعات (Infobox) صفحه که حاوی داده‌های ساختاریافته کلیدی مانند تاریخ تولد، محل تولد، آثار و... است، به صورت HTML استخراج می‌گردد.

- تجزیه ویکی‌داده (`parse_wikidata`): اطلاعات موجود در مدخل ویکی‌داده (Wiki-data) متضایر با آن شخص، که معمولاً دقیق‌ترین و ساختاریافته‌ترین داده‌ها را شامل می‌شود، بازیابی می‌شود.

۳. ادغام و اولویت‌بندی داده‌ها: در این مرحله حیاتی، داده‌های استخراج شده از سه منبع فوق با یکدیگر ادغام می‌شوند. یک منطق اولویت‌بندی پیاده‌سازی شده است: اطلاعات ویکی‌داده به دلیل اعتبار بالاتر در اولویت اول قرار دارند، پس از آن جعبه اطلاعات، و در نهایت اطلاعات استخراجی از متن خلاصه.

۴. تکمیل و پالایش با مدل زبانی بزرگ (`fillm_fill`): پس از ادغام اولیه، شیوه‌ای JSON ممکن است هنوز فیلدهای خالی یا ناقصی داشته باشد. در این مرحله، کل اطلاعات جمع‌آوری شده به همراه شیوه‌ای ناقص به یک مدل زبانی بزرگ، Gemma (LLM) یعنی، ارسال می‌شود. مدل وظیفه دارد تا با درک محتوای متنی، فیلدهای باقی‌مانده را پر کرده، اطلاعات موجود را پالایش نماید و در صورت لزوم، فرمت آنها را استانداردسازی کند (مثلاً تبدیل تاریخ‌ها به یک فرمت یکسان). این مرحله به خصوص برای استخراج اطلاعاتی که در بخش‌های ساختاریافته موجود نبودند، بسیار کارآمد است.

۵. ذخیره‌سازی و مدیریت نرخ درخواست: پس از تکمیل شیوه‌ای JSON نهایی برای آن شخص در فایل خروجی نوشته می‌شود. برای جلوگیری از اعمال بار اضافی بر روی سرورهای ویکی‌پدیا و

رعایت سیاست‌های استفاده منصفانه، یک تأخیر کوتاه (sleep polite 0.5s) بین درخواست‌ها برای هر شخص اعمال می‌گردد.

۶. تکرار: حلقه به سراغ شخص بعدی در فایل ورودی رفته و کل فرآیند تکرار می‌شود تا زمانی که داده‌های تمام مشاهیر استخراج و پردازش شوند.

این پایپ‌لاین ترکیبی، با بهره‌گیری همزمان از داده‌های ساختاریافته و قدرت درک متنه مدل‌های زبانی بزرگ، به ما این امکان را داد تا یک مجموعه‌داده غنی، دقیق و تا حد امکان کامل تولید کنیم.

در نهایت داده یک نمونه دا به شکل زیر می‌شود:

```
0:
  name: "کامبیز آتابای"
  sex: "male"
  nick-names: []
  birth:
    date: "1939-02-02"
    location:
      province: "تهران"
      city: "تهران"
      coordinates:
        latitude: "35.6895"
        longitude: "51.3890"
    death:
      date: ""
      location: { province: "", city: "", coordinates: {} }
      tomb_location: { province: "", city: "", coordinates: {} }
      era: "دودمان پهلوی، جمهوری اسلامی ایران"
  occupation:
    0: "مدیر فوتیال"
    1: "مربي"
  works:
    0: "مدیر کل فنی و خدمات عمومی در دریار پهلوی"
    1: "رئیس دفتر فرج پهلوی در نیویورک"
    2: "دهمین رئیس فدراسیون فوتیال ایران"
    3: "نششمین رئیس کنفراسیون فوتیال آسیا"
  events: []
  image: [ "https://commons.wikimedia.org/wiki/Special:FilePath/Kambiz_Atabay.jpg" ]
```

شکل ۴-۲: نمونه JSON پر شده پس از این مرحله

۱-۲-۲ گردآوری و تجمعی دادگان جامع از مشاهیر ایرانی

پس از موفقیت فاز اولیه در گردآوری داده‌های یک حوزه خاص (سیاست‌مداران)، پروژه به فاز اصلی خود، یعنی ایجاد یک مجموعه‌داده‌ی جامع و چند‌حوزه‌ای از مشاهیر ایرانی، وارد شد. برای این منظور، داده‌های استخراج‌شده از حوزه‌های متنوعی که هر کدام توسط یک گروه مجزا پردازش شده بودند، تجمعی گردید. این حوزه‌ها شامل شخصیت‌های سیاسی، هنری، ورزشی، علمی و دیگر چهره‌های برجسته تاریخ و فرهنگ ایران بودند.

گام نخست، یکپارچه‌سازی و ادغام داده‌های خام از تمام گروه‌ها بود. با این حال، به دلیل تفاوت‌های جزئی در فرآیندهای استخراج و ماهیت هر حوزه، یک مرحله‌ی دقیق پاک‌سازی (Cleaning) بر روی

کل دادگان تجمعی شده الزامی بود. این فرآیند شامل حذف نمونه‌های تکراری، اصلاح خطاهای رایج در انکدینگ متن، و استانداردسازی اولیه فیلدها بود.

۲-۲-۲ بررسی و برچسب‌گذاری داده‌های جمع آوری شده

پس از پاکسازی اولیه، مهم‌ترین گام یعنی ارزیابی و تضمین کیفیت داده‌ها آغاز شد. برای این هدف، از ابزار متن‌باز **Studio Label** استفاده گردید. بخشی از داده‌ها که دارای ابهامات آشکار یا خطاهای ساختاری بودند، پیش از ورود به فرآیند برچسب‌زنی، به صورت دستی توسط تیم پروژه اصلاح شدند.

سپس، نمونه‌های باقی‌مانده برای ارزیابی صحت و کیفیت اطلاعات، میان دو برچسب‌گذار (Anno-tator) توزیع گردید. هدف از این کار، سنجش میزان توافق بین فردی بود که یک شاخص کلیدی برای ارزیابی پایداری و قابل اتکا بودن دادگان است. پس از اتمام برچسب‌زنی، ضربیب کاپای کوهن (Co-hen's) محاسبه شد و به مقدار 0.947 ± 0.008 دست یافتیم. این امتیاز بالا، نشان‌دهنده‌ی یک تطابق و توافق بسیار قوی بین دو برچسب‌گذار بود و کیفیت بالای دستورالعمل‌های برچسب‌زنی و همچنین خود داده‌ها را تأیید می‌کرد.

در گام نهایی، موارد معدودی که بین دو برچسب‌گذار توافق وجود نداشت، توسط یک شخص ثالث (Adjudicator) به دقت بازبینی و نسخه صحیح نهایی‌سازی شد. این فرآیند تضمین کرد که مجموعه‌داده‌ی نهایی از بالاترین سطح دقت و اعتبار برخوردار باشد و به عنوان یک منبع قابل اطمینان برای مراحل بعدی پروژه، یعنی آموزش مدل‌های چندوجهی، مورد استفاده قرار گیرد.

۳-۲ بهبود دادگان

هدف از این بخش، ارتقاء کیفیت و غنای دادگان موجود برای استفاده در مدل‌های زبانی و سیستم‌های پردازش متن فارسی است. با توجه به اینکه داده‌های اولیه شامل اطلاعات پراکنده و ناهمگون بودند، مجموعه‌ای از فرایندهای پردازشی طراحی و اجرا گردید تا داده‌ها به شکل یکپارچه، کامل و قابل اعتماد درآیند.

ابتدا با استفاده از مدل‌های زبانی پیشرفته، برای هر شخصیت زندگی‌نامه‌های فارسی روان و منسجم تولید شد تا اطلاعات ساختاریافته به متن طبیعی تبدیل گردد. سپس تصاویر مرتبط با هر شخصیت پردازش شدند و مدل توصیف‌کننده‌ی چهره با پرامپت‌های دقیق به کار گرفته شد تا توضیحات مختصر و استانداردی از ویژگی‌های ظاهری افراد تولید شود. این توضیحات تصویری با داده‌های متئی در فضای برداری هم‌تراز

شدند تا قابلیت استفاده همزمان در تحلیل‌ها و وظایف مختلف مانند بازیابی اطلاعات فراهم گردد.

در ادامه، داده‌های متنی و تصویری به کمک فرایнд مرج و همسانسازی ادغام شدند. این کار شامل نرمال‌سازی نوشتار فارسی، تطبیق دقیق و فازی رکوردها و سیاست مشخص برای رفع شناسه‌های تکراری بود. نتیجه‌ی نهایی، مجموعه‌ای یکپارچه از داده‌های متنی و تصویری است که نه تنها کامل‌تر و غنی‌تر از نسخه اولیه می‌باشد، بلکه برای ریزنظمی مدل‌های زبانی، آموزش مدل‌های چندوجهی، و توسعه کاربردهای هوش مصنوعی در زبان فارسی بسیار مناسب است.

بنابراین، فرایند بهبود دادگان تضمین می‌کند که داده‌های تولیدشده دارای کیفیت بالا، تنوع مناسب، و سازگاری ساختاری باشند و بتوانند به عنوان زیرساختی مطمئن برای پژوهش‌ها و کاربردهای آینده مورد استفاده قرار گیرند.

۱-۳-۲ تولید متن برای هر شخص از داده‌های غیر تصویری جمع‌آوری شده

در این بخش، زندگی‌نامه‌های فارسی به صورت خودکار و بر اساس داده‌های ساختاریافته تولید شدند. برای این کار، از مدل‌های زبانی پیشرفته نظری AI Metis و gemini flash lite preview استفاده گردید که توانایی بالایی در تولید متن‌های فارسی روان و دقیق دارند. فرایند تولید به این صورت بود که ابتدا پرامپت‌های تخصصی طراحی شدند تا تنها از اطلاعات موجود در داده‌ها استفاده شود، فیلهای خالی یا نامشخص نادیده گرفته شوند، متن خروجی در قالب یک پاراگراف تولید شود، و آرایه‌ها (مانند مشاغل یا آثار) با حرف ربط «و» به هم متصل گردد.

ارتباط با مدل‌ها از طریق API انجام شد و برای مدیریت خطاهای احتمالی، مکانیزم retry همراه با تأخیر نمایی در نظر گرفته شد. همچنین، پس از دریافت خروجی مدل، توابع پردازش متن طراحی گردید تا نشانه‌های اضافی حذف شوند، متن نهایی تمیز و خوانا گردد و فقط محتواهای اصلی باقی بماند. نتیجه این فرایند، تولید زندگی‌نامه‌هایی منسجم، طبیعی، و بدون اضافه‌سازی بود که علاوه بر دقت محتوایی، برای ریزنظمی مدل‌های زبانی فارسی نیز مناسب هستند.

برای مثال، زندگی‌نامه‌ای مانند زیر تولید شده است: علی‌اکبر دهخدا، در سال ۱۲۵۷ خورشیدی در تهران به دنیا آمد و در سال ۱۳۳۴ در همان شهر درگذشت. او به عنوان لغتشناس، نویسنده، و سیاستمدار فعالیت می‌کرد. از آثار شاخص او می‌توان به لغت‌نامه دهخدا، امثال و حکم، و چرند و پرنداشته نمود. او در دوره قاجار و پهلوی زندگی می‌کرد و تأثیرات عمیقی بر فرهنگ و ادبیات فارسی گذاشت.

```

Convert the following JSON biographical data into a flowing Persian text
paragraph.

STRICT RULES:
- Only use information explicitly provided in the JSON
- Do NOT add any information not in the JSON
- Skip null, empty, or missing fields
- Write only one paragraph in Persian

PROPERTY HANDLING:
- name: Start with the full name
- birth.date: Can be string OR object {{year, month, day}} - extract year
if string
- death: Skip if null or date is missing/empty
- occupation: If array, join with "و"
- works: If array of objects, extract titles only
- events: Extract title and description, ignore null fields
- era: Include if not "نامشخص"

Example:
Input: {"name": "ابونصر منصور", "birth": {"date": "960", "location": "حدود میانه"}, "death": {"date": "1036"}, "occupation": "ستاره‌شناس، ریاضیدان", "works": [{"titles": "مثبات"}]}
ابونصر منصور در حدود سال ۹۶۰ در کیلان به دنیا آمد و در سال ۱۰۳۶ درگذشت. او
بعنوان ستاره‌شناس و ریاضیدان فعالیت می‌کرد. از آثار شاخص او می‌توان به "مثبات" اشاره نمود.

Now convert this JSON:


Output:

```

شکل ۲-۵: پرامپت استفاده شده به مدل برای تولید متن

۲-۳-۲ تولید توضیحات تصویر اشخاص به متن داده ها

در این بخش، از تصاویر موجود برای هر شخصیت استفاده شد تا توضیحات ظاهری آنها به صورت متن فارسی تولید گردد. برای این منظور، از مدل GPT-4.1 mini که توانایی بالایی در تشخیص چهره و استخراج ویژگی‌های بصری دارد، بهره گرفته شد. پرامپت طراحی شده شامل دستورالعمل‌های دقیق بود تا توصیف چهره در حداکثر دو جمله و به زبان فارسی ارائه شود. در این توصیفات ویژگی‌هایی مانند شکل صورت، بینی، چشم‌ها، ابروها، مو، سبیل، ریش، و رنگ پوست ذکر گردید و در صورت امکان، سن تقریبی فرد نیز تخمین زده شد.

به منظور حفظ کیفیت داده‌ها، تصاویری که وضوح کافی نداشتند یا به‌طور واضح چهره‌ی شخص را نشان نمی‌دادند، حذف گردیدند. در چنین مواردی مدل طبق پرامپت تنها عبارت «UNCLEAR» را بازمی‌گرداند تا نشان دهد تصویر معتبر نیست. خروجی نهایی این بخش توضیح مختصر و دقیق ویژگی‌های چهره هر فرد بود که به داده‌های متنه زندگی‌نامه افزوده شد و در کنار آنها، توصیفی ترکیبی و کامل‌تر از هر شخصیت تاریخی یا معاصر ارائه گردید.

```

prompt = """
Please analyze this facial image and provide a description in Persian following these rules:
1. The description must be concise and a maximum of two sentences.
2. Mention the main facial features such as face shape, nose, eyes, eyebrows, hair, mustache, beard and skin.
3. If an approximate age is detectable, mention it.
4. If the image is unclear or of low quality and the face cannot be recognized, just say "UNCLEAR" (without quotes).

Example of valid description:
"برخی از صورت بیشتر شکل، بینی میتوانند، چشم‌های پرورشی، موهای متفاوت و ریش کوتاه، به نظر می‌رسد در دهه [نام] زیستگی باشند.

Example of unclear image response:
"UNCLEAR"
"""

```

شکل ۲-۶: پرامپت استفاده شده به مدل برای تولید توصیف عکس

در ادامه، برای یکپارچه‌سازی داده‌های متنی و تصویری، از روش‌های image embedding و text embedding استفاده شد. توصیف‌های متنی تولید شده از تصاویر به گونه‌ای طراحی شدند که در فضای embedding برداری نزدیک به تع؟ رهای متنی زندگی نامه قرار گیرند. این هم ترازو سازی (alignment) باعث شد داده‌های متنی و تصویری قابلیت مقایسه و استفاده همزمان در فرآیندهای بعدی مانند بازیابی اطلاعات و ریزنظمی مدل‌های زبانی را داشته باشند.

۳-۳-۲ مرج کردن داده‌های جفت گروه

در این مرحله، داده‌های متنی و تصویری که به صورت جداگانه پردازش و تولید شده بودند، با یکدیگر ادغام شدند تا مجموعه‌ای یکپارچه از اطلاعات برای هر شخصیت حاصل گردد. برای همسان‌سازی شناسه‌ها و نام‌ها، ابتدا فرآیند نرمال‌سازی با استفاده از ابزار Hazm انجام شد تا تفاوت‌های ظاهری در نوشتار فارسی (مانند فاصله‌های اضافی یا تفاوت در حروف) برطرف گردد. سپس تطبیق رکوردها در دو سطح صورت گرفت:

۱. **مچ دقیق (Exact Match):** در صورتی که شناسه یا نام فرد در هر دو مجموعه داده به‌طور دقیق یکسان بود، همان رکوردها با هم ادغام شدند.

۲. **مچ فازی (Fuzzy Match):** اگر تطبیق مستقیم وجود نداشت، از الگوریتم‌های شbahت متنی (fuzzy matching) با آستانه‌ی ۹۰٪ استفاده شد تا موارد مشابه ولی نه کاملاً یکسان، شناسایی و با هم ترکیب شوند.

در مورد رکوردهایی که دارای شناسه تکراری بودند، سیاست ما انتخاب تصادفی یکی از تصاویر موجود برای حفظ تنوع داده‌ها بود. همچنین، داده‌های تصویری و متنی از هر دو مجموعه با اولویت قرار دادن نسخه‌ی کامل‌تر و تمیزتر در هم ادغام شدند. در نهایت، داده‌های بدون همتا از هر مجموعه نیز به مجموعه ادغام شده افزوده شدند تا هیچ اطلاعاتی از دست نرود.

این فرآیند منجر به ایجاد یک پایگاه داده‌ی یکپارچه شد که هم زندگی نامه‌ی متنی و هم توضیحات تصویری هر شخصیت را در خود جای داده و قابلیت استفاده در مراحل بعدی مانند ریزتنظیم مدل‌های زبانی و تحلیل‌های ترکیبی را دارد.

۴-۲ ساخت مدل Encoder برای RAG

پس از گردآوری و پالایش مجموعه‌داده، مرحله بعدی، ساخت و آموزش یک مدل Encoder قدرتمند است که بتواند نمایش برداری (Embedding) معناداری از داده‌های متنی (زندگی نامه) و تصویری (چهره مشاهیر) تولید کند. هدف اصلی این است که در فضای برداری تولید شده، زندگی نامه و تصاویر مربوط به یک شخص خاص، به یکدیگر نزدیک و از داده‌های مربوط به سایر افراد، دور باشند. این ویژگی، سنگ بنای یک سیستم بازیابی اطلاعات (Retrieval) دقیق و کارآمد است.

در این پروژه، ما از یک معماری دو-مسیره (Two-Tower) چندوجهی بهره بردیم. برج متنی (Text-Tower) از مدل clip-ViT-B-32-multilingual-v1 [۱] که یک مدل چندزبانه قدرتمند است، و برج تصویری (Image Tower) از انکودر تصویر مدل CLIP [۲] با پیش‌آموزش laion2b تشکیل شده است. برای تخصصی کردن این مدل‌ها بر روی دادگان مشاهیر ایرانی، آن‌ها را با استفاده از یادگیری مقابله‌ای ^۱ بهینه‌سازی ^۲ کردیم. فرآیند کلی پیاده‌سازی شده در نوت‌بوک NLP_encoding_V4.ipynb بازیابی مبتنی بر FAISS است که در ادامه به تفصیل شرح داده می‌شوند.

۴-۳ پیش‌پردازش و آماده‌سازی داده‌ها برای مدل

آماده‌سازی داده‌ها اولین گام حیاتی در ساخت یک مدل قابل اعتماد است. این فرآیند شامل پاک‌سازی متون و مدیریت مسیرهای تصاویر بود.

پردازش و اعتبارسنجی مسیر تصاویر: داده‌های تصویری ما در چندین پوشه مختلف قرار داشتند و ستون مربوطه در فایل CSV حاوی لیست مسیرهای نسبی یا نام فایل‌ها بود. مجموعه‌ای از توابع کمکی (resolve_many, resolve_one_path, _parse_images_field) برای پردازش این ستون طراحی شد. این توابع، رشته‌های متنی را به لیست‌های پایتون تبدیل کرده و سپس برای هر مسیر، با جستجو در

Learning Contrastive^۱
Fine-tune^۲

پوشه‌های تعریف شده (CFG.image_roots)، مسیر مطلق و قابل دسترس فایل را پیدا می‌کنند. در نهایت، رکوردهایی که هیچ تصویر معتبری برای آنها یافت نشد، از مجموعه داده حذف گردیدند تا از بروز خطا در حین آموزش جلوگیری شود.

پیش‌پردازش متن: برای متون زندگی‌نامه، از کلاس TextPreprocessor که بر پایه کتابخانه hazm [۳] ساخته شده، استفاده گردید. این کلاس وظیفه نرمال‌سازی متون فارسی را بر عهده دارد که شامل یکسان‌سازی کاراکترها (مانند تبدیل "ی" و "ك" عربی به "ی" و "ک" فارسی) و حذف علائم نگارشی اضافی است. این مرحله به کاهش حجم واژگان و افزایش ثبات در نمایش متون کمک می‌کند.

نرمال‌سازی متن: یک تابع نرمال‌سازی (normalize_digits_months) برای استاندارد‌سازی متون زندگی‌نامه پیاده‌سازی شد. این تابع ارقام فارسی و عربی را به معادل انگلیسی آنها تبدیل کرده و نام ماههای فارسی را با شماره عددی آنها جایگزین می‌کند. این کار به یکپارچگی داده‌های ورودی به مدل متنی کمک شایانی می‌کند.

۲-۴-۲ بهینه‌سازی مدل برای تولید Embedding

برای تطبیق انکودرهای متن و تصویر با دامنه خاص پروژه، از یادگیری مقابله‌ای درون-دسته‌ای [۳] استفاده کردیم. در این روش، برای هر نمونه در یک بچ (Batch) سایر نمونه‌های موجود در همان بچ به عنوان نمونه‌های منفی [۴] در نظر گرفته می‌شوند. تابع هزینه CLIP-style Contrastive Loss تلاش می‌کند تا شباهت کسینوسی بین زوج‌های تصویر و متن متناظر (مثبت) را در بچ بیشینه و شباهت آنها با سایر زوج‌های نامتناظر (منفی) را کمینه سازد.

دو استراتژی بهینه‌سازی موازی را مورد بررسی قرار دادیم:

استراتژی اول: بهینه‌سازی کامل برج متنی: در این رویکرد، انکودر تصویر CLIP ثابت نگه داشته شد (پارامترهای آن منجمد یا frozen شدن) و تنها پارامترهای مدل متنی چندزبانه (mclip) و یک لایه MultiImageContrastiveDataset کلاس proj_txt (proj) برای آموزش فعال شدند. داده‌ها را به صورت زوج‌های (تصویر، متن) آماده کرده و به مدل ارائه می‌دهد. این استراتژی به مدل متنی اجازه می‌دهد تا خود را برای تولید بردارهایی که به بهترین شکل با بردارهای تصویری از پیش آموخته شده

Learning Contrastive In-Batch^۳
Samples Negative^۴

منطبق هستند، وفق دهد.

استراتژی دوم: بهینه‌سازی فقط لایه‌های انتباطی:^۵ این رویکرد، یک روش بسیار بهینه‌تر از نظر محاسباتی است. در این استراتژی، هر دو انکودر اصلی متن و تصویر کاملاً منجمد باقی می‌مانند. تنها پارامترهایی که آموزش داده می‌شوند، یک لایه پروجکشن خطی کوچک برای برج متنی (TIHeads.txt) و پارامتر مقیاس‌دهنده لاجیت (logit_scale) هستند. کلاس HeadOnlyDataset داده‌ها را به صورت (بردار متن از پیش محاسبه شده، تصویر) به مدل می‌دهد. هدف این استراتژی، یادگیری یک تبدیل خطی ساده است که بتواند فضای برداری متن را به فضای برداری تصویر نگاشت دهد، بدون آنکه خود انکودرها تغییر کنند. این روش بسیار سریع‌تر است و خطر بیش‌بازارش (Overfitting) را کاهش می‌دهد.

در نهایت، پس از اجرای هر دو استراتژی، مدلی که بهترین عملکرد را روی مجموعه اعتبارسنجی^۶ داشت، برای مراحل بعدی انتخاب و ذخیره گردید.

۳-۴-۲ ساخت سیستم بازیابی (Retrieval)

پس از بهینه‌سازی مدل انکودر، یک پایگاه داده برداری^۴ با استفاده از کتابخانه FAISS [۴] برای جستجوی سریع و کارآمد ایجاد شد. این فرآیند شامل مراحل زیر است:

۱. تولید Embedding برای کل مجموعه‌داده: ابتدا با استفاده از مدل بهینه‌سازی شده، تمام متون زندگی‌نامه و تصاویر موجود در دادگان به بردارهای embedding با ابعاد ۵۱۲ تبدیل شدند. برای هر شخص که چندین تصویر داشت، یک بردار تصویر میانگین از embedding تمام تصاویرش محاسبه شد.

۲. ایجاد Embedding ترکیبی (Fusion): برای هر شخص، دو نوع بردار نهایی تولید شد: یکی فقط بردار متن (text_doc_emb) و دیگری یک بردار ترکیبی (fusion_doc_emb) که از ترکیب وزن دار بردار متن و بردار تصویر میانگین با ضریب $\alpha = 0.7$ به دست آمد. این ترکیب به سیستم اجازه می‌دهد تا از هر دو وجهه اطلاعاتی (متن و تصویر) به صورت همزمان بهره ببرد.

۳. نرمال‌سازی و ساخت Index: تمام بردارهای تولید شده، نرمال‌سازی $2L$ شدند تا طول آن‌ها در محاسبه شباهت تأثیری نداشته باشد. سپس، دو Index، یکی در FAISS (IndexFlatIP) برای

Fine-tuning Head-Only^۵
Set Validation^۶
Database Vector^۷

بردارهای متنی و بردارهای ترکیبی ساخته شد. این ها Index امکان جستجوی بسیار سریع بر اساس ضرب داخلی (معادل شباهت کسینوسی برای بردارهای نرمال شده) را فراهم می‌کنند.

این ساختار دوگانه به ما این امکان را می‌دهد که بسته به نوع کوئری، یا فقط در فضای متنی یا در فضای چندوجهی ترکیبی به جستجو بپردازیم.

۴-۴-۲ ارزیابی عملکرد سیستم بازیابی

پس از ساخت های FAISS Index برای دو رویکرد مختلف (بازیابی متنی بر متن و بازیابی ترکیبی)، ضروری است که عملکرد آنها را به صورت کمی و کیفی ارزیابی کنیم. هدف این ارزیابی، سنجش توانایی سیستم در بازیابی صحیح زندگی نامه (سنده) مربوط به یک شخص، با استفاده از یک کوئری (متشكل از متن و تصویر) است. این مرحله پیش از اتصال سیستم به مدل تولیدکننده، (Generator) به ما اطمینان می‌دهد که بخش بازیابی (Retrieval) از دقت و کارایی لازم برخوردار است.

آماده‌سازی مجموعه داده ارزیابی: برای ارزیابی، از یک زیرمجموعه از دادگان که در فرآیند آموزش و اعتبارسنجی مدل استفاده نشده بود، بهره بردیم. برای هر رکورد در این مجموعه تست، یک کوئری ساخته شد. هر کوئری شامل متن سوال (از ستون questions_json) و یکی از تصاویر مرتبط با همان شخص است. این ساختار، سناریوی واقعی استفاده از سیستم را شبیه‌سازی می‌کند که در آن کاربر ممکن است یک سوال متنی به همراه یک تصویر نمونه ارائه دهد.

فرآیند ارزیابی و تولید Embedding کوئری: برای هر کوئری در مجموعه تست، یک بردار ترکیبی Embedding با استفاده از مدل Encoder بهینه‌سازی شده تولید گردید. این بردار از ترکیب وزن دار بردار متن سوال و بردار تصویر آن با یک ضریب $\alpha_q = 0.7$ به دست آمد. سپس این بردار کوئری برای جستجو در دو FAISS Index مجزای Index استفاده شد:

۱. **Index متنی:** فقط شامل بردارهای متنی زندگی نامه‌ها.

۲. **Index ترکیبی (Fusion):** شامل بردارهای ترکیبی (متن + تصویر) زندگی نامه‌ها.

برای هر جستجو، $K = 5$ سنده برتر که بیشترین شباهت (ضرب داخلی) را با بردار کوئری داشتند، بازیابی شدند.

معیارهای ارزیابی کمی: عملکرد دو رویکرد با استفاده از معیارهای استاندارد بازیابی اطلاعات (In-Retrieval) formation سنجیده شد. در اینجا، "پاسخ صحیح" به معنای بازیابی سندی است که ID آن با ID شخص موجود در کوئری یکسان باشد.

- **Recall@K:** این معیار، درصد کوئری‌هایی را محاسبه می‌کند که پاسخ صحیح در میان K نتیجه برتر بازیابی شده، وجود داشته باشد. ما این معیار را برای $\{1, 5, 20\} \in K$ محاسبه کردیم. برای مثال، $Recall@1$ (که معادل Accuracy است) نشان می‌دهد که در چند درصد موارد، اولین نتیجه بازگشتی دقیقاً سند صحیح بوده است.

- **MRR: Rank Reciprocal Mean** •
این معیار، میانگین معکوس رتبه اولین پاسخ صحیح را محاسبه می‌کند. فرمول آن به صورت $MRR = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{1}{rank_i}$ است که در آن $|Q|$ تعداد کوئری‌ها و $rank_i$ رتبه اولین سند صحیح برای کوئری i است. MRR بالا نشان می‌دهد که سیستم به طور متوسط، پاسخ صحیح را در رتبه‌های بسیار بالای لیست نتایج قرار می‌دهد.

نتایج و تحلیل: نتایج ارزیابی به وضوح برتری رویکرد ترکیبی (Fusion) را بر رویکرد صرفاً متنی نشان داد. مقادیر معیارهای Recall@K و MRR برای مدل ترکیبی به طور معناداری بالاتر بود. این بهبود نشان می‌دهد که افزودن اطلاعات تصویری به فرآیند بازیابی، توانایی سیستم را در تفکیک افراد و یافتن اسناد مرتبط به شدت افزایش می‌دهد و به غلبه بر ابهامات موجود در داده‌های متنی کمک می‌کند.

ارزیابی کیفی و بصری: در نهایت طبق تصویر ۷-۲ که خروجی ارزیابی ما هست میبینیم که که مقادیر Hit@k برای مقادیر مختلف k بدین شکل هست:

K	Count	Accuracy@1	Hit@K	Recall@K	Route	Precision@K	F1@K	MRR@K	MedianRank
0	1	80	0.7	0.7000	0.7000	NaN	NaN	NaN	NaN
1	5	80	0.7	0.8375	0.8375	NaN	NaN	NaN	NaN
2	20	80	0.7	0.9250	0.9250	NaN	NaN	NaN	NaN
3	1	80	0.7	0.7000	0.7000	text_e5	0.70000	0.700000	0.700000
4	5	80	0.7	0.8375	0.8375	text_e5	0.16750	0.279167	0.755000
5	20	80	0.7	0.9250	0.9250	text_e5	0.04625	0.088095	0.764125

شکل ۷-۲: خروجی ارزیابی مدل بازیابی برای کوئری‌های تولید شده

این ارزیابی نشان می‌دهد که مدل بازیابی ما آماده برای استفاده در سیستم RAG می‌باشد.

۵-۲ ساخت مدل end-to-end برای RAG

پس از آموزش و ارزیابی موفقیت‌آمیز مدل Encoder چندوجهی که وظیفه بازیابی اطلاعات (Retrieval) را بر عهده دارد، گام نهایی، اتصال این بخش به یک مدل زبان بزرگ (LLM) به عنوان بخش تولیدکننده (Generator) بود تا پایپ‌لاین کامل بازیابی-افزایش-تولید (RAG) شکل گیرد. این سیستم یکپارچه قادر است با دریافت یک سوال (چه به صورت متنی و چه چندوجهی)، فرآیند را از بازیابی اطلاعات تا تولید پاسخ نهایی به صورت خودکار انجام دهد.

۱-۵-۲ معماری و اجزای سیستم

سیستم RAG پیاده‌سازی شده از سه بخش اصلی تشکیل شده است:

۱. **رابط ورودی (Input-Interface):** این بخش سوال کاربر را به همراه تصویر (در صورت وجود) دریافت می‌کند.

۲. **مدل بازیاب (Retriever):** این همان مدل Encoder چندوجهی است که در فصل قبل توسعه داده شد. تابع `retrieve_context_auto` مسئولیت مدیریت این بخش را بر عهده دارد. این تابع با بررسی وجود تصویر در ورودی، به صورت هوشمند مسیر بازیابی را انتخاب می‌کند:

- **حالت چندوجهی (Fusion):** اگر سوال همراه با تصویر باشد، تابع `search_fusion` فراخوانی می‌شود که از بازنمایی‌های ترکیبی متن و تصویر برای یافتن مرتبطترین اسناد استفاده می‌کند.

- **حالت فقط متنی (Text-only):** در غیاب تصویر، تابع `search_text_rag` فعال شده و بازیابی صرفاً بر اساس محتوای متنی سوال انجام می‌شود.

خروجی این بخش، لیستی از K سند برتر (در این پروژه $K = 5$) است که شامل متن بیوگرافی و امتیاز شباهت آنها با پرسش است.

۳. **مدل تولیدکننده (Generator):** این بخش، اطلاعات بازیابی شده را به یک پاسخ منسجم و نهایی تبدیل می‌کند. برای این منظور، از مدل زبان بزرگ `Qwen/Qwen2-7B-Instruct` استفاده شد. این مدل به دلیل عملکرد قوی در زبان فارسی و قابلیت پیروی از دستورالعمل‌ها انتخاب گردید.

۲-۵-۲ فرآیند تولید پاسخ

فرایند تولید پاسخ برای سوالات چهارگزینه‌ای (MCQA) در چند مرحله کلیدی انجام می‌شود که توسط تابع answer_single_mcq_simple مدیریت می‌گردد:

۱. بازیابی زمینه (**Context-Retrieval**) ابتدا، با استفاده از تابع `retrieve_context_auto`، متون مرتبط با سوال از پایگاه دانش بازیابی می‌شوند.

۲. ساخت پرامپت (**Prompt-Engineering**): اطلاعات بازیابی شده به همراه سوال اصلی و گزینه‌ها در یک قالب مشخص به نام پرامپت (**Prompt**) سازماندهی می‌شوند. تابع `build_mcq_prompt_simple` این وظیفه را بر عهده دارد. در طراحی پرامپت، به مدل به صراحت دستور داده می‌شود که:

- فقط بر اساس متون بازیابی شده پاسخ دهد.

- خروجی را در قالب یک ساختار JSON مشخص شامل دو کلید answer_index (شماره گزینه صحیح) و reason (توضیح مختصر) برگرداند.

این روش، استخراج پاسخ از خروجی مدل را بسیار پایدار و قابل اعتماد می‌سازد. بخشی از پرامپت فارسی طراحی شده به شرح زیر است:

```
user = (
    f"سوال: {question}\n\n"
    f"گزینه ها:\n{opts}\n\n"
    f"متون بازیابی شده:\n{ctx}\n\n"
)
print(f"\n فقط براساس متون بالا پاسخ بده . اگر جواب صحیح نیست، نزدیکترین گزینه را حداکثر یک حرف بزن "
      f"باشد (بدون هیچ متن اضافه) JSON خروجی «فقط و فقط» این است "
      f'[{{"answer_index": X, "reason": "..."}}]'
)
```

شکل ۲-۸: پرامیت تولید پاسخ پرای مدل RAG

۳. تولید پاسخ توسط LLM: پرامپت نهایی به مدل Qwen2-7B-Instruct ارسال می‌شود. تابع generate_answer با تنظیمات مشخصی مانند `temperature=0.5` و `top_p=0.9`، پاسخ مدل را تولید می‌کند.

۴. استخراج و اعتبارسنجی پاسخ: خروجی خام مدل توسطتابع `parse_mcq_json_only` پردازش می‌شود تا ساختار JSON از آن استخراج شود. در صورتی که مدل به هر دلیلی فرمت JSON را رعایت نکرده باشد، یک راهکار جایگزین (Fallback) فعال می‌شود که با شمارش تکرار کلمات

هر گزینه در متون بازیابی شده، محتمل‌ترین پاسخ را انتخاب می‌کند. این کار پایداری سیستم را در مقابل خطاهای احتمالی مدل زبان افزایش می‌دهد.

این پایپ‌لاین یکپارچه که توسطتابع `answer_mcq_batch_simple` بر روی کل مجموعه داده ارزیابی اجرا می‌شود، به ما اجازه می‌دهد تا عملکرد سیستم End-to-End را به صورت کمی و با محاسبه معیار دقت (Accuracy) اندازه‌گیری کنیم.

فصل ۳

نتایج و دستاوردها

در این فصل، به بررسی نتایج نهایی حاصل از پیاده‌سازی و ارزیابی مدل RAG چندوجهی و همچنین ارائه دستاوردهای عملی پروژه می‌پردازیم. این فصل به سه بخش اصلی تقسیم می‌شود: ارزیابی کمی مدل یکپارچه، End-to-End، ارائه یک دموی تحت وب برای تعامل زنده با مدل، و انتشار مدل‌های آموزش‌دیده برای استفاده عمومی در جامعه پژوهشی.

۱-۳ ارزیابی مدل نهایی RAG End-to-End

پس از اطمینان از عملکرد دقیق بخش‌های Encoder و Retriever، این دو بخش به یک مدل زبان بزرگ (LLM) به عنوان بخش Generator متصل شدند تا سیستم کامل RAG شکل گیرد. وظیفه نهایی این سیستم، پاسخ به سوالات چهارگزینه‌ای در دو حالت متنی-تصویری (Multimodal) و فقط متنی (Text-only) است. به این صورت که مدل با دریافت سوال، گزینه‌ها و زمینه بازیابی شده (شامل متن و تصویر)، گزینه صحیح را از بین چهار گزینه موجود انتخاب می‌کند.

برای ارزیابی عملکرد کلی این سیستم یکپارچه، یک مجموعه داده ارزیابی شامل انواع سوالات طراحی گردید. این سوالات به دو دسته اصلی تقسیم می‌شوند:

۱. سوالات چندوجهی (Multimodal): در این نوع سوالات، علاوه بر متن سوال، یک تصویر نیز به عنوان ورودی ارائه می‌شود که برای پاسخ صحیح به سوال، تحلیل آن ضروری است. نمونه‌ای از این سوالات در شکل ۱-۳ نشان داده شده است.

۲. سوالات فقط متنی (Text-only): این سوالات تنها شامل متن هستند و برای پاسخ به آن‌ها،

اطلاعات متنی بازیابی شده کفایت می‌کند. نمونه‌ای از این سوالات در شکل ۲-۳ قابل مشاهده است.

```
{
  "id": 1,
  "question": "این شخص کیم و چه فعالیتهای داشته است؟",
  "image_path": "/content/drive/MyDrive/images_clean/250px-Media_conference_of_Abajan_at_Fajr_festival-8.png",
  "options": [
    "سعید آقامعائی - بازیگر، فیلم‌نامه‌نویس و کارگردان سینما",
    "حسین بنامی - بازیگر و کارگردان سینما و روزنامه‌نگار فاریب",
    "کیومرث مازی - نویسنده و مترجم از "محمد شاهیده پور - کارگردان تلویزیون"
  ],
  "correct_answer": 0,
  "category": "cinema"
},
```

شکل ۱-۳: نمونه‌ای از یک سوال چهارگزینه‌ای چندوجهی در مجموعه داده ارزیابی. در این نوع سوال، مدل باید با تحلیل همزمان متن و تصویر، گزینه صحیح را انتخاب کند.

```
{
  "id": 1,
  "question": "کدام یک از این افراد در دوره قاجار به عنوان موسیقی‌دان و شاعر فعالیت داشته است؟",
  "options": [
    "ابوحفص سعدی", "نادر گلچین", "داود آزاد", "سیما بیتا"
  ],
  "correct_answer": 0,
  "category": "music"
},
{
  "id": 2,
  "question": "کدام شخصیت به عنوان اولین زن گردشگر فضایی و اولین ایرانی‌تبار در فضا شناخته می‌شود؟",
  "options": [
    "نادیا مفتونی", "انوشه انصاری", "زهرا شجاعی", "انسیه خزعلی"
  ],
  "correct_answer": 1,
  "category": "science"
},
```

شکل ۲-۳: نمونه‌ای از سوالات چهارگزینه‌ای فقط متنی در مجموعه داده ارزیابی.

۱-۱-۳ معیارهای ارزیابی

از آنجایی که وظیفه نهایی مدل، یک مسئله انتخاب از بین چند گزینه (MCQ) است که می‌توان آن را نوعی طبقه‌بندی در نظر گرفت، از معیارهای استاندارد ارزیابی مدل‌های طبقه‌بندی استفاده شد:

- **دقت (Accuracy):** این معیار، اصلی‌ترین سنجه برای این وظیفه است و نسبت تعداد پاسخ‌های صحیح پیش‌بینی شده توسط مدل به کل تعداد سوالات را اندازه‌گیری می‌کند. این معیار به صورت کلی نشان می‌دهد که مدل در چند درصد از موارد توانسته گزینه درست را انتخاب کند.

$$\text{Accuracy} = \frac{\text{تعداد پاسخ‌های صحیح}}{\text{تعداد کل سوالات}} \quad (1-3)$$

- **معیارهای F-Score، Recall و Precision - Score (به تفکیک هر دسته):** برای ارزیابی دقیق‌تر عملکرد مدل در هر دسته موضوعی (Category) از سوالات، معیارهای زیر محاسبه می‌گردند:

- **دقت (Precision):** از بین تمام مواردی که مدل برای یک دسته خاص پیش‌بینی کرده، چه کسری از آن‌ها واقعاً متعلق به آن دسته بوده‌اند.

- بازخوانی (Recall) از بین تمام موارد واقعی یک دسته خاص، مدل چه کسری از آنها را به درستی تشخیص داده است.

- امتیاز F₁: میانگین همساز (Harmonic-Mean) بین Precision و Recall که یک معیار ترکیبی و متوازن از عملکرد مدل در هر دسته ارائه می‌دهد.

۲-۱-۳ تحلیل نتایج کمی و کیفی

برای ارزیابی کمی مدل End-to-End، ما عملکرد آن را بر روی مجموعه داده آزمون شامل ۵۰ سوال چهارگزینه‌ای سنجیدیم. در این مرحله، ارزیابی تنها با استفاده از مؤلفه متنی سیستم (یعنی حالتی که هیچ تصویری به عنوان ورودی ارائه نمی‌شود) انجام شد تا یک خط پایه (Baseline) قوی برای مقایسه با مدل چندوجهی در آینده ایجاد شود.

نتایج ارزیابی مدل پایه متنی (Text-only) در جدول ۱-۳ خلاصه شده است. همان‌طور که مشاهده می‌شود، مدل تنها با استفاده از بازیابی متنی موفق شد به دقت کلی ۷۸٪ بر روی تمام ۵۰ سوال دست یابد. این دقت، نشان‌دهنده توانایی بالای مدل Encoder متنی در بازیابی اسناد مرتبط و قابلیت مدل Generator در استنتاج پاسخ صحیح از متون ارائه شده است.

بر روی داده‌های همراه با تصویر این دقت به ۵۰ درصد می‌رسد. که در کارهای آینده باید بهبود یابد.

تحلیل دقیق‌تر نتایج بر اساس دسته‌های موضوعی، نکات جالبی را آشکار می‌سازد. مدل در دسته‌هایی مانند پژوهشی، سیاست، فناوری و فرهنگ به دقت کامل ۱۰۰٪ دست یافته است. این موضوع نشان می‌دهد که بیوگرافی‌های موجود در این حوزه‌ها اطلاعات دقیق و صریحی را برای پاسخ به سوالات فراهم کرده‌اند. همچنین، در دسته‌های پر تکراری مانند موسیقی (۱۱ سوال) و سینما (۸ سوال)، مدل به ترتیب به دقت‌های قابل توجه ۸۷٪ و ۸۱٪ رسیده است.

با این حال، چالش‌برانگیزترین دسته برای مدل، حوزه علمی (science) بود که در آن دقت مدل به تنها ۲۰٪ کاهش یافت. تحلیل کیفی خطاهای این دسته نشان داد که سوالات مطرح شده نیازمند استنتاج‌های پیچیده‌تر یا اطلاعاتی بودند که به صورت پرآکنده در متن بیوگرافی وجود داشت و مدل در اتصال این قطعات به یکدیگر برای رسیدن به پاسخ صحیح دچار مشکل شده بود. همچنین، دسته ادبیات (literature) با دقت ۶۲٪ عملکرد متوسطی از خود نشان داد که می‌تواند به دلیل زبان استعاری و پیچیدگی‌های بیشتر متون این حوزه باشد.

این نتایج کمی و کیفی، ضمن اثبات کارایی مدل RAG متنی، نقاط ضعف آن را نیز به خوبی مشخص می‌کند و اهمیت افزودن اطلاعات چندوجهی (تصویری) را برای پوشش این کاستی‌ها، به ویژه در دسته‌هایی

جدول ۳-۱: نتایج ارزیابی مدل RAG در حالت فقط متنی بر اساس دسته‌بندی موضوعی

دسته‌بندی موضوعی (Category)	تعداد سوالات	دقت (Accuracy)
ادبیات (literature)	۸	%۶۲
پزشکی (medical)	۵	%۱۰۰
سیاست (politics)	۴	%۱۰۰
سینما (cinema)	۸	%۸۷
علمی (science)	۵	%۲۰
فناوری (technology)	۲	%۱۰۰
فرهنگ (culture)	۱	%۱۰۰
موسیقی (music)	۱۱	%۸۱
مهندسی (engineering)	۱	%۱۰۰
هنری (arts)	۱	%۱۰۰
دانشگاهی (academic)	۲	%۵۰
رسانه (media)	۱	%۱۰۰
سرگرمی (entertainment)	۱	%۱۰۰
کلی (Overall)	۵۰	%۷۸


که شناسایی بصری شخصیت می‌تواند به پاسخ کمک کند، دوچندان می‌سازد.

۲-۳ پیاده‌سازی و ارائه دموی تحت وب Web-Demo

به منظور نمایش قابلیت‌های عملی و فراهم آوردن امکان تعامل زنده با سیستم RAG چندوجهی توسعه‌داده شده، یک دموی تحت وب با استفاده از کتابخانه Gradio طراحی و در پلتفرم Hugging Face Spaces میزبانی شد. این دمو به کاربران اجازه می‌دهد تا با وارد کردن یک سوال متنی و آپلود یک تصویر (اختیاری)، به صورت آنی پاسخ تولید شده توسط مدل را مشاهده کنند (مشابه تصویر ۳-۳).

۱-۲-۳ آدرس دسترسی و مشخصات دمو

دموی تعاملی پروژه در آدرس زیر در دسترس عموم قرار دارد:



شکل ۳-۳: نمای بستره که در آن مدل نهایی آپلود شده و طرز کار آن

huggingface.co/spaces/ahm1378/multimodal-rag-demo

نسخه به کار گرفته شده در این دموی عمومی، به دلیل محدودیت‌های منابع سخت‌افزاری رایگان در پلتفرم Face Hugging Face (که تنها CPU در اختیار قرار می‌دهد)، از یک مدل سبک‌تر استفاده می‌کند. به همین دلیل، ممکن است سرعت پاسخ‌دهی (Latency) در مقایسه با اجرای مدل روی سخت‌افزار GPU بالاتر بوده و دقت آن نیز به دلیل استفاده از یک مدل تولیدکننده (Generator) کوچک‌تر، اندکی کمتر از مدل نهایی ارائه شده در این پژوهش باشد. با این حال، این دمو به خوبی معماری کلی سیستم و نحوه تعامل چندوجهی آن را به نمایش می‌گذارد و به عنوان یک اثبات مفهوم Concept of Proof عمل می‌کند. رابط کاربری آن به شکلی طراحی شده است که علاوه بر پاسخ نهایی، اسناد و تصاویر بازیابی شده که به عنوان زمینه برای تولید پاسخ استفاده شده‌اند را نیز نمایش می‌دهد تا فرآیند کارکرد RAG برای کاربر شفاف باشد.

۳-۳ انتشار مدل نهایی در Hugging-Face

در راستای ترویج پژوهش باز و قابل تکرار، مدل Encoder چندوجهی نهایی که در این پژوهه آموزش داده شده است، به همراه تمام فایل‌های مورد نیاز برای استفاده، در پلتفرم منتشر گردید. این کار به سایر

پژوهشگران و توسعه‌دهنگان این امکان را می‌دهد که به سادگی مدل ما را دانلود کرده و از آن برای کاربردهای مشابه یا به عنوان یک مدل پایه (Baseline) قوی در پروژه‌های خود استفاده کنند.

huggingface.co/ahm1378/finetune-clip-fa-head

۴-۳ انتشار کد و داده‌ها در Github

در نهایت تمام داده‌ها و کد‌ها در لینک زیر قابل دسترسی هست.

github.com/NLP-Final-Projects/Mashahir

فصل ۴

نتیجه‌گیری و کارهای آینده

در این پژوهش، هدف اصلی طراحی و پیاده‌سازی یک سیستم پرسش و پاسخ چندوجهی- (Multimodal- QA) مبتنی بر معماری بازیابی-افزایش-تولید (RAG) برای دامنه دانش عمومی مرتبط با افراد و شخصیت‌های ایرانی بود. چالش اصلی، کمبود مجموعه داده‌های چندوجهی ساختاریافته در زبان فارسی و نیاز به مدلی بود که بتواند به طور همزمان از اطلاعات متنی و تصویری برای پاسخ به سوالات بهره ببرد.

۱-۱ خلاصه دستاوردها

برای رسیدن به این هدف، مراحل زیر با موفقیت طی شد:

- **ساخت مجموعه داده:** ابتدا، یک مجموعه داده جامع شامل بیوگرافی متنی و تصاویر مرتبط با شخصیت‌های ایرانی از منابعی نظری و یکی‌پدیا و ویکی‌داده استخراج و پالایش شد. این مجموعه داده به عنوان پایگاه دانش^۱ سیستم عمل می‌کند.
- **توسعه Encoder چندوجهی:** یک مدل Encoder دوگانه (Dual-Encoder) با استفاده از مدل‌های زبانی پیش‌آموزش دیده برای متن (مانند mCLIP) و مدل‌های بینایی برای تصویر (مانند CLIP) توسعه داده شد. این مدل با استفاده از یادگیری تقابلی^۲ به گونه‌ای آموزش داده شد که بتواند بازنمایی‌های (Embeddings) متنی و تصویری مرتبط با یک شخص را در فضای برداری به یکدیگر نزدیک کند. این همترازی، اساس عملکرد بخش Retriever سیستم است.

Base Knowledge^۱
Learning Contrastive^۲

• پیاده‌سازی سیستم RAG یکپارچه: مدل Encoder آموزش دیده به عنوان بخش Retriever در یک پایپ‌لاین کامل RAG به کار گرفته شد. این سیستم قادر است برای یک سوال ورودی (متنی یا چندوجهی)، مرتبط‌ترین اسناد متنی و تصویری را از پایگاه دانش بازیابی کرده و آن‌ها را به عنوان زمینه (Context) در اختیار یک مدل زبان بزرگ (LLM) به عنوان Generator قرار دهد تا پاسخ نهایی را تولید کند.

• ارزیابی و نمایش نتایج: عملکرد سیستم نهایی بر روی یک مجموعه سوالات چهارگزینه‌ای ارزیابی شد. نتایج نشان داد که مدل چندوجهی پیشنهادی با دستیابی به دقت ۷۸٪، عملکرد نسبتاً خوبی دارد. این بهبود، مؤید توانایی سیستم در بهره‌گیری از اطلاعات تصویری برای افزایش دقت پاسخ‌دهی است. علاوه بر این، یک دموی تحت وب برای نمایش قابلیت‌های عملی سیستم پیاده‌سازی و منتشر گردید.

۲-۴ محدودیت‌ها و کارهای آینده

علیرغم نتایج امیدوارکننده، این پژوهش با محدودیت‌هایی نیز همراه بود. کیفیت و جامعیت پایگاه دانش مستقیماً بر عملکرد سیستم تأثیرگذار است و جمع‌آوری داده‌های باکیفیت‌تر همچنان یک چالش محسوب می‌شود. همچنین، مدل Generator استفاده شده در این پژوهش یک مدل عمومی بود و آموزش دقیق‌تر آن بر روی دامنه خاص پژوهه می‌توانست به تولید پاسخ‌های طبیعی‌تر و دقیق‌تر منجر شود.

برای کارهای آینده، مسیرهای زیر پیشنهاد می‌گردد:

• گسترش پایگاه دانش: افزودن اطلاعات بیشتر و متنوع‌تر، از جمله ویدیو و صوت، برای ساخت یک سیستم RAG با قابلیت‌های چندوجهی غنی‌تر.

• بهینه‌سازی مدل Generator: آموزش دقیق (Fine-tuning) مدل زبان بزرگ بر روی وظیفه پرسش و پاسخ مبتنی بر زمینه بازیابی شده، به منظور بهبود کیفیت و سبک پاسخ‌ها.

• ارزیابی انسانی: انجام ارزیابی توسط کاربران انسانی برای سنجش معیارهای نظری میزان رضایت، طبیعی بودن پاسخ‌ها و مفید بودن اطلاعات بازیابی شده که توسط معیارهای خودکار قابل اندازه‌گیری نیستند.

• بررسی معماری‌های پیشرفته‌تر: تحقیق بر روی معماری‌های جدیدتر RAG که اطلاعات متنی و تصویری را به شکل عمیق‌تری با یکدیگر ادغام می‌کنند (Fusion-in-Decoder) به جای ارائه آن‌ها به عنوان زمینه صرف.

در مجموع، این پروژه با موفقیت نشان داد که استفاده از معماری RAG چندوجهی راهکاری مؤثر برای ساخت سیستم‌های پرسش و پاسخ هوشمند در زبان فارسی است و زیربنای مناسبی برای تحقیقات آتی در این حوزه فراهم می‌آورد.

Bibliography

- [1] N. Reimers and I. Gurevych. Sentence-bert: Sentence embeddings using siamese bert-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 3982–3992, Hong Kong, China, 11 2019. Association for Computational Linguistics.
- [2] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, et al. Learning transferable visual models from natural language supervision. In *International conference on machine learning*, pages 8748–8763. PMLR, 2021. CLIP Encoder
- [3] A. Nourian et al. Hazm: Python library for digesting persian text. <https://github.com/sobhe/hazm>, 2017. Hazm
- [4] J. Johnson, M. Douze, and H. Jégou. Billion-scale similarity search with GPUs. In *IEEE Transactions on Big Data*, volume 7, pages 535–547. IEEE, 2019. FAISS
- [5] D. Vrandečić and M. Krötzsch. Wikidata: A free collaborative knowledge base. *Communications of the ACM*, 57(10):78–85, 2014. (Wikidata)
- [6] O. Medelyan, D. Milne, C. Legg, and I. H. Witten. Mining meaning from wikipedia. In *Putting semantic web in practice*, pages 115–151. Springer, 2009.
- [7] Google. Gemma: Open Models by Google, 2024. Gemma

- [8] M. Tkachenko, M. Malykh, A. Kovalev, N. Vakhrushev, A. Holmanyuk, and A. Shelmanov. Label Studio: A versatile data annotation tool. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, pages 1–8, 2021. Label Studio
- [9] J. Cohen. A coefficient of agreement for nominal scales. *Educational and psychological measurement*, 20(1):37–46, 1960. (Cohen’s Kappa)
- [10] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen. LoRA: Low-Rank Adaptation of Large Language Models. In *International Conference on Learning Representations*, 2021. LoRA